




基于神经渲染的三维场景重建与自然 语言相机控制研究

杨皓然*

北京交通大学软件学院

June 18, 2026

*电子邮件: 2330142@bjtu.edu.cn, 学号: 23301142

摘要： 神经渲染把三维图形学中的相机投影、可见性建模和体渲染过程与可学习场景表示结合起来，为多视角图像驱动的三维重建和新视角合成提供了新的技术路线。本文围绕 NeRF Synthetic 数据集中的 Lego 场景，比较传统显式重建基线、Nerfacto 和 Splatfacto 三类流程在新视角合成任务中的表现，并进一步设计自然语言相机控制实验，考察大语言模型将镜头描述转换为可渲染相机轨迹的能力。实验结果表明，在 20 个测试视角上，Visual Hull 基线取得 15.62 dB PSNR 和 0.701 SSIM，Nerfacto 提升到 21.13 dB 和 0.873，Splatfacto 进一步提升到 28.28 dB 和 0.955，说明神经场和三维高斯表示能够显著改善受控合成场景的新视角合成质量。在相机控制实验中，规则模板和 LLM 生成的 8 条轨迹均能通过 JSON 解析、参数合法性检查和 Nerfstudio camera path 转换；人工评分显示，LLM 在复合镜头任务中相对单主动作规则近似具有更好的语义符合度。本文最后讨论神经渲染在图像质量、效率、可编辑性和控制性之间的取舍。本文代码见：https://github.com/Lxlorange/CG_final。

关键词： 神经渲染；NeRF；3D Gaussian Splatting；新视角合成；相机轨迹；大语言模型

Abstract: Neural rendering combines camera projection, visibility modeling, and volume rendering in computer graphics with learnable scene representations. This paper studies 3D reconstruction and novel view synthesis on the Lego scene from the NeRF Synthetic dataset. We compare a traditional explicit Visual Hull baseline, Nerfacto, and Splatfacto, and further evaluate language-driven camera control by converting natural-language shot descriptions into renderable Nerfstudio camera paths. On 20 test views, Visual Hull obtains 15.62 dB PSNR and 0.701 SSIM, while Nerfacto improves the results to 21.13 dB and 0.873, and Splatfacto achieves 28.28 dB and 0.955. These results show the advantage of neural field and 3D Gaussian representations for controlled novel-view synthesis. In the camera-control experiment, both rule-based and LLM-generated trajectories pass JSON parsing, parameter validation, and camera-path conversion. The LLM-based method can additionally produce keyframed compound trajectories, making it more expressive than single-action rule templates for complex shot descriptions. The code used in this article can be found in https://github.com/Lxlorange/CG_final.

Key words: neural rendering; NeRF; 3D Gaussian Splatting; novel view synthesis; camera path; large language model

目录

1	引言	4
2	相关工作	4
2.1	传统多视图重建与显式渲染	4
2.2	NeRF 与神经场表示	5
2.3	3D Gaussian Splatting	5
2.4	自然语言相机控制	5
3	方法	6
3.1	总体流程	6
3.2	场景表示与渲染模型	6
3.3	自然语言相机轨迹生成	6
4	实验设计	7
4.1	数据集与实现细节	7
4.2	评价指标	7
5	实验结果与分析	7
5.1	新视角合成定量结果	7
5.2	新视角合成定性结果	8
5.3	LLM 相机控制客观结果	9
5.4	LLM 相机控制主观评分	10
6	讨论	10
6.1	质量与表示形式的关系	10
6.2	效率与工程限制	10
6.3	控制性与可编辑性	11
6.4	局限性	11
7	结论	11
A	LLM 相机轨迹生成 Prompt 示例	11

1 引言

从多视角图像恢复可渲染三维场景是计算机图形学和计算机视觉的交叉问题。传统图形学管线通常依赖显式几何、材质、纹理、光照和相机参数：对于真实场景，常见流程是先通过 **Structure from Motion (SfM)** 估计相机位姿，再通过 **Multi-View Stereo (MVS)** 或轮廓约束恢复点云、体素或网格，最后进行纹理映射和显式渲染。该类流程结构清晰，几何和材质对象具有较强可解释性，便于导入建模软件或实时渲染引擎；但当场景存在细小结构、反光表面、遮挡边界、弱纹理区域或不完整视角覆盖时，显式重建和纹理修复成本较高。

神经渲染改变了这一流程中“先获得精确显式模型，再渲染图像”的假设。Tewari 等将神经渲染概括为结合经典图形学和生成式学习的图像或视频合成方法，其核心在于对相机、几何、外观、光照和语义等控制变量进行显式或隐式建模 [1]。NeRF 进一步把静态场景表示为从三维位置和观察方向到体密度、颜色的连续函数，并通过体渲染方程合成图像 [2]。3D Gaussian Splatting (3DGS) 则使用可优化三维高斯集合表示场景，通过投影和 alpha 合成实现高效渲染 [3]。这些方法不再要求首先提取完整网格，而是直接从图像监督中优化可渲染表示。

本文关注两个问题。第一，神经渲染相对传统显式基线在受控三维重建和新视角合成中能带来多大质量提升，其失败形式又有什么差异。第二，当场景表示已经训练完成后，如何更高效地控制渲染视角，尤其是能否使用自然语言描述生成相机轨迹。前者对应“表示和渲染质量”的问题，后者对应“控制接口”的问题。二者共同决定了神经渲染流程能否从实验室图像合成走向可交互的内容生产流程。

本文贡献如下：第一，构建了 Visual Hull、Nerfacto 和 Splatfacto 在同一 Lego 场景、同一测试视角上的对比实验，并报告 PSNR、SSIM、最差视角和定性失败案例。第二，设计了规则模板与 LLM 相机控制对比实验，把自然语言镜头描述转换为 JSON 参数，再生成 Nerfstudio camera path 并渲染视频。第三，围绕表示形式、渲染质量、控制性和局限性分析传统图形管线、NeRF 类方法与 3DGS 方法的差异。

2 相关工作

2.1 传统多视图重建与显式渲染

传统三维重建流程通常以显式场景表示为中心。COLMAP 等系统通过 SfM 完成特征匹配、稀疏重建和相机位姿估计，再通过 MVS 获得稠密点云或深度图 [4, 5]。随后可以进一步进行网格化、纹理映射、材质估计和光照设置。显式流程的优势是对象边界清楚，点、面、纹理和材质都有明确语义，因此便于检查、编辑和复用。其弱点是中间步骤误差会逐级传播：位姿不准会影响深度估计，深度噪声会影响网格，纹理缝合又会带来接缝和模糊。

本文使用 Visual Hull 作为传统显式基线。Visual Hull 利用多视角轮廓约束恢复物体外壳，不需要神经网络训练，适合展示纯几何投影流程的能力边界。它能恢复物体大致轮廓，但无法恢复轮廓内部的凹陷、遮挡细节和视角相关外观，因此可作为与神经渲染方法对比的保守基线。

2.2 NeRF 与神经场表示

NeRF 使用多层感知机表示连续辐射场，输入空间位置 $\mathbf{x}$ 和观察方向 $\mathbf{d}$ ，输出体密度 σ 和颜色 $\mathbf{c}$ ，再沿相机射线积分得到像素颜色 [2]。该思想把三维一致性约束引入图像监督，使模型能够在训练视角附近合成连续变化的新视角。Xie 等对 *neural fields* 的综述指出，坐标网络可以统一表示形状、外观、密度、运动等多种视觉计算对象 [6]。

原始 NeRF 的主要代价来自大量射线采样和 MLP 查询。后续工作从编码、采样和显式存储结构等方向改进效率与质量。例如 Instant-NGP 使用多分辨率哈希编码显著提升训练速度 [7]，Plenoxels 和 TensoRF 用稀疏体素或张量分解降低连续网络查询成本 [8, 9]，Mip-NeRF 系列从抗锯齿和尺度建模角度改进视角合成质量 [10, 11, 12]。Nerfacto 是 Nerfstudio 中面向实际使用的 NeRF 类管线，整合了多种工程化设计，因此本文选用它代表 NeRF 类神经渲染流程。

2.3 3D Gaussian Splatting

3DGS 用一组三维高斯描述场景，每个高斯具有位置、协方差、透明度和视角相关颜色等参数，并通过可微 *splatting* 优化这些参数 [3]。与 NeRF 沿射线密集采样不同，3DGS 先把三维高斯投影到屏幕空间，再在局部 *tile* 内排序和 *alpha* 合成。这种半显式表示减少了大量 MLP 查询，更接近 GPU 光栅化式并行渲染，通常具有较高渲染速度。

3DGS 的局限同样来自其表示形式。三维高斯不是严格的拓扑表面，优化后可能出现漂浮高斯、过大高斯或多视角不一致的局部结构。近期工作尝试从几何、材质和编辑性角度改进这一问题，例如 SuGaR 从高斯中提取可编辑网格 [13]，GaussianShader 为反光表面引入着色函数 [14]，GaussianEditor 探索文本驱动的三维高斯编辑 [15]，2D Gaussian Splatting 则通过面向表面的二维高斯增强几何一致性 [16]。这些工作说明 3DGS 的高效性和可编辑性仍需要在具体任务中权衡。

2.4 自然语言相机控制

完成三维表示训练后，用户仍需要指定相机路径来生成视频或展示视角。传统方式依赖手动关键帧、脚本参数或固定模板，适合简单轨迹，如环绕、推进、拉远和平移，但难以直接表达“先从高处揭示，再下降并绕到右前方”这类复合镜头语义。近年来，生成式 AI 已经被用于把语义任务转化为结构化规划结果。Arjun P S 等人在目标导航任务中使用 LLM 和 LVLM 理解场景语义结构，并生成面向目标搜索的高层子目标 [17]。该工作给本文实验提供了直接启发：自然语言并不直接控制底层执行器，而是先被转化为一组可执行的中间规划单元；在本文中，这些中间单元对应相机半径、方位角、俯仰角、视场角和关键帧。

与机器人导航中的子目标规划类似，神经渲染视频生成也需要把抽象镜头意图转化为可执行相机轨迹。ChatCam 面向相机控制提出了 CineGPT，即用于文本条件相机轨迹生成的 GPT-based autoregressive model，并结合 Anchor Determinator 确定轨迹在三维场景中的放置位置 [18]。这一工作说明，专门训练的相机控制模型可以解释复杂镜头指令并生成可用

于辐射场渲染的视频轨迹。本文实验的直接依据仍是 Cognitive Planning 工作中“自然语言任务 → 中间规划表示 → 可执行控制”的思想；与 ChatCam 不同，本文没有训练 CineGPT 类专用模型，而是选择 OpenAI-compatible API 作为轻量替代，通过 prompt 约束通用 LLM 输出严格 JSON，并把自然语言镜头描述解析为 camera path 参数和可选关键帧。这样可以在不构建专用训练集和不训练新模型的条件下来验证语言驱动相机控制的可行性，但其上限也受通用 API 对结构化输出和空间运动理解能力的限制。

3 方法

3.1 总体流程

本文将实验流程分为两部分。第一部分是新视角合成质量对比：输入同一 Lego 场景的训练视角图像和相机参数，分别构建 Visual Hull、Nerfacto 和 Splatfacto 表示，并在 20 个测试视角上导出 RGB 图像。第二部分是相机控制实验：给定中文镜头描述，分别用规则模板和 LLM 生成相机参数 JSON，再转换为 Nerfstudio camera path，最后用已训练的 Splatfacto 模型渲染视频。

两部分实验的关系是：第一部分验证哪种场景表示更适合作为最终渲染后端，第二部分验证在固定渲染后端上如何更灵活地控制视角。由于 Splatfacto 在第一部分中取得最高图像质量，第二部分使用 Splatfacto 作为视频渲染模型。

3.2 场景表示与渲染模型

Visual Hull 基线使用训练图像的 alpha mask 对三维体素空间进行轮廓雕刻，得到显式外壳，再根据训练视角颜色进行投影采样和 point splatting 渲染。该基线不包含神经网络优化，代表传统几何约束流程。

Nerfacto 和 Splatfacto 均通过 Nerfstudio 训练。Nerfacto 表示连续神经辐射场，主要计算代价来自射线采样和网络查询；Splatfacto 表示可优化三维高斯集合，主要代价来自高斯投影、tile 排序和 alpha 合成。两者使用相同数据集和测试视角，以减少数据划分差异带来的影响。

3.3 自然语言相机轨迹生成

相机轨迹参数统一采用结构化 JSON 表示，包含轨迹类型、帧数、起止半径、起止方位角、起止俯仰角、视场角和注视点。对于复合镜头，LLM 还可以输出 keyframes 字段，每个关键帧包含归一化时间 t 、相机半径、俯仰角、方位角和视场角。转换脚本优先使用关键帧分段插值；如果没有关键帧，则使用起止参数线性插值。

规则模板根据任务的预期类型生成单一动作轨迹，包括 orbit、dolly、pan、tilt 和 orbit_dolly。对于包含多个阶段的复合任务，本文将规则基线定义为“单主动作近似”：即从描述中抽取一个主要运动阶段并生成对应模板轨迹，而不额外设计多阶段规则解析器。这一设置使规则基线保持简单、可解释，但也意味着它不是完整的复合镜头规划方法。

LLM 方法则通过 prompt 要求模型输出严格 JSON，并在复合任务中优先输出 compound 类型和 3 到 5 个关键帧。Prompt 中显式给出字段 schema、数值范围、轨迹类型枚举和复合镜头关键帧约束，并规定所有轨迹持续看向 look_at，避免模型输出解释性文本或不可渲染参数。附录 A 给出了本文使用的 prompt 模板示例。

4 实验设计

4.1 数据集与实现细节

实验使用 NeRF Synthetic 数据集中的 lego 场景。该场景具有透明背景、已知相机参数和稳定静态物体，适合在受控条件下分析三维表示差异。新视角合成实验使用 20 个测试视角评估图像质量。Visual Hull、Nerfacto 和 Splatfacto 的预测图像均被整理到统一目录后计算指标。

神经渲染部分使用 Nerfstudio。Nerfacto 与 Splatfacto 均训练 30000 次迭代。LLM 相机控制实验复用已训练的 Splatfacto 配置，并通过 ns-render camera-path 渲染生成视频。自然语言解析部分调用 OpenAI-compatible API，本次实验使用的模型为 deepseek-chat，温度参数为 0.2，超时时间为 60 s。

4.2 评价指标

新视角合成实验使用 PSNR 和 SSIM 作为客观图像指标。PSNR 反映像素误差，SSIM 反映局部结构相似性。除平均值外，本文还报告标准差和最差测试视角，用于观察跨视角稳定性。LPIPS 尚未计算，因此本文不把感知相似性作为定量结论。

相机控制实验使用三类指标。第一类是结构化输出成功率，包括 JSON 解析率、参数合法率和 camera path 生成率。第二类是几何轨迹指标，包括轨迹连续性和目标保持率：连续性由相邻相机位置最大步长归一化得到，目标保持率检查相机前向方向是否持续指向 look_at。第三类是人工主观评分，考察视频是否符合文字意图、运动是否平滑、目标是否保持在画面中。主观评分由本文作者完成，因此评分结果反映单人观察下的任务符合度判断。

5 实验结果与分析

5.1 新视角合成定量结果

表 1: Lego 场景 20 个测试视角上的新视角合成结果

方法	PSNR $\uparrow$	最差 PSNR	SSIM $\uparrow$	最差 SSIM
Visual Hull	15.62 ± 0.33	15.06	0.701 ± 0.014	0.685
Nerfacto	21.13 ± 2.07	17.91	0.873 ± 0.032	0.815
Splatfacto	28.28 ± 4.25	23.41	0.955 ± 0.018	0.923

表 1 表明，Visual Hull 基线的平均 PSNR 为 15.62 dB，平均 SSIM 为 0.701，明显低于

两种神经渲染方法。Nerfacto 将 PSNR 提升到 21.13 dB，SSIM 提升到 0.873，说明连续辐射场能够比轮廓外壳更好地拟合物体颜色和可见性。Splatfacto 取得最高的 28.28 dB PSNR 和 0.955 SSIM，相比 Visual Hull 提升 12.66 dB，相比 Nerfacto 提升 7.15 dB，说明三维高斯表示在该受控合成场景中具有更高的新视角合成质量。

同时，Splatfacto 的 PSNR 标准差为 4.25 dB，高于 Nerfacto 的 2.07 dB。这说明 Splatfacto 的平均质量最高，但不同视角之间仍存在质量波动。其最差视角 PSNR 为 23.41 dB，仍显著高于 Nerfacto 和 Visual Hull 的最差视角，说明该波动没有改变总体优势。

5.2 新视角合成定性结果



图 1: Lego 测试视角的定性对比。各列对应不同测试视角，各行依次为真实图像、Visual Hull、Nerfacto 和 Splatfacto。

图 1 展示了三种方法的视觉差异。Visual Hull 能恢复 Lego 模型的大致轮廓，但细杆、车轮和边缘区域容易出现破碎和空洞，颜色也存在明显混合。这与其表示能力直接相关：轮廓外壳只能描述所有 silhouette 约束的交集，不能恢复轮廓内部凹陷和视角相关外观。




图 2: 三种方法在各自最差视角上的失败案例。Visual Hull 表现为外壳缺失和点状破碎；Nerfacto 表现为边缘软化和局部模糊；Splatfacto 表现为局部颜色漂移或残余浮点。

Nerfacto 的整体结构更完整，背景干扰更少，但在边缘和高频结构处存在软化。这类现象来自体密度场的连续性和射线积分平均效应。Splatfacto 的边缘更锐利，细节和颜色更接近真实图像，但在最差视角中仍可能出现局部漂浮高斯或颜色偏移。图 2 说明，三种方法的失败机制不同：传统基线受显式几何外壳限制，NeRF 类方法受连续体场和平滑采样影响，3DGS 则受离散高斯分布、尺度和排序影响。

5.3 LLM 相机控制客观结果

表 2: 规则模板与 LLM 相机轨迹生成的结构化指标

方法	任务数	JSON 解析率	参数合法率	Camera path 生成率	平均连续性
规则模板	8	1.00	1.00	1.00	0.882
LLM	8	1.00	1.00	1.00	0.897

表 2 给出了相机轨迹生成的客观统计。规则模板和 LLM 在 8 个任务上均达到 100% 的 JSON 解析率、参数合法率和 camera path 生成率，说明二者都能够形成可被 Nerfstudio 接收的结构化轨迹。LLM 的平均连续性为 0.897，略高于规则模板的 0.882；两者目标保持率均为 1.00，说明生成轨迹在几何上都能持续看向物体中心。

仅从这些客观指标看，二者差距不大，因为这些指标主要检查“能否渲染”和“是否平滑”，而不直接判断镜头是否符合自然语言意图。LLM 的优势主要体现在复合任务表达上。例如 high_reveal_orbit 要求先从高处俯视、再下降、最后绕到右前方；单主动作规则近似只能保留其中一个主要阶段，而 LLM 可以通过关键帧表达多个阶段。因此，语义符合度需要结合人工观看视频后的主观评分分析。

表 3: 相机控制视频主观评分表, 评分者为本文作者。

任务	规则模板评分	LLM 评分
水平环绕一圈	3	4
正面缓慢推进特写	5	5
从左向右平移	2	2
从俯视下降到平视	3	4
半圈环绕并逐渐拉远	4	4
高处俯视揭示后绕到右前方	2	5
正面特写拉远并绕到左前方	2	4
低角度对角线扫动并升高	2	2
平均分	2.88	3.75

5.4 LLM 相机控制主观评分

主观评分采用 1–5 分制, 由本文作者在观看每个渲染视频后给出: 5 分表示完全符合文字意图、运动平滑且目标稳定; 4 分表示基本符合, 仅有轻微构图或速度问题; 3 分表示大体方向正确但镜头控制一般; 2 分表示只执行了部分意图; 1 分表示明显失败或无法渲染。表 3 显示, 规则模板的平均分为 2.88, LLM 的平均分为 3.75。二者在正面推进特写和半圈环绕拉远等单动作或弱复合任务上差距较小, 说明固定模板对常见镜头具有一定有效性; 在“高处俯视揭示后绕到右前方”和“正面特写拉远并绕到左前方”等复合任务上, LLM 能够通过关键帧表达阶段变化, 得分明显高于单主动作规则近似。三个复合任务的平均分中, 规则模板为 2.00, LLM 为 3.67, 说明自然语言到关键帧的映射更适合描述多阶段镜头意图。

6 讨论

6.1 质量与表示形式的关系

实验结果支持一个清晰结论: 在相机准确、场景静态、训练视角充分覆盖的受控合成数据中, 神经渲染方法显著优于简单显式几何基线。Visual Hull 的误差来自表示上限, 外壳无法表达凹陷和复杂可见性; Nerfacto 通过连续辐射场缓解这一问题, 但体渲染的平滑性会带来边缘软化; Splatfacto 使用半显式高斯集合, 在保持可优化外观的同时提高了细节锐度, 因此在本文实验中取得最高指标。

6.2 效率与工程限制

从理论上讲, NeRF 类方法的渲染代价与射线数量、采样点数和网络查询成本相关, 3DGS 则把主要代价转移到高斯投影、排序和 α 合成。本文记录到 Visual Hull 的平均单视角渲染时间约为 1.24 s, 但未将 Nerfacto 和 Splatfacto 的单帧渲染时间纳入统一计时实验, 因此效率部分只讨论复杂度来源和工程趋势, 不把不同流程的端到端耗时作为主要结论。

6.3 控制性与可编辑性

图像质量提升并不等价于控制性提升。传统显式流程的网格、纹理和材质可直接编辑；NeRF 类表示把几何和外观耦合在网络参数中，局部编辑较困难；3DGS 的高斯集合比纯 MLP 更局部，但仍不是严格拓扑表面。相机控制实验说明，LLM 可以改善“如何指定镜头”的交互接口，但它并不直接解决场景几何和材质的可编辑问题。换言之，LLM 提升的是控制语言到相机参数的映射能力，神经渲染提升的是图像合成质量，二者作用在管线的不同环节。

6.4 局限性

本文仍有三点局限。第一，实验仅覆盖 NeRF Synthetic Lego 单场景，结论不能直接推广到真实采集数据和复杂材质场景。第二，本文未计算 LPIPS，也未对 Nerfacto 与 Splatfacto 进行统一单帧计时，因此感知质量和效率比较仍不完整。第三，相机控制评分来自人工观看视频后的单次主观评价，能够反映本实验中的语义符合度差异，但仍缺少多评价者一致性检验。

7 结论

本文围绕三维场景重建、新视角合成和自然语言相机控制，比较了传统 Visual Hull 基线、Nerfacto 和 Splatfacto 三类流程。Lego 场景实验表明，神经渲染方法在 PSNR 和 SSIM 上显著优于显式外壳基线，其中 Splatfacto 取得最高图像质量。定性结果进一步显示，不同表示的失败机制具有明显差异：传统基线受轮廓外壳限制，Nerfacto 易出现边缘软化，Splatfacto 则可能出现局部漂浮高斯或颜色偏移。

在相机控制实验中，规则模板和 LLM 都能生成合法 camera path；主观评分显示，LLM 在 8 个任务上的平均分为 3.75，高于规则模板的 2.88，优势主要来自复合镜头任务。该结果说明，自然语言到关键帧的映射能够作为神经渲染视频生成的有效控制接口。后续工作应补充多场景和真实场景实验、LPIPS 与统一渲染时间统计，并引入多评价者主观评分，以更完整地评价神经渲染管线在质量、效率、可编辑性和交互控制方面的综合表现。

A LLM 相机轨迹生成 Prompt 示例

本文使用的 prompt 目标是把中文镜头描述约束为可直接解析的 JSON 对象，而不是让模型自由生成自然语言说明。实际模板包含四类约束：第一，限定模型角色为三维神经渲染相机轨迹规划器；第二，要求只输出一个 JSON 对象，不输出 Markdown 或解释；第三，给出轨迹类型、字段名称和数值范围；第四，对复合镜头要求输出单调递增的关键帧。核心模板如下。

你是一个三维神经渲染相机轨迹规划器。你的任务是吧中文镜头描述转换为严格 JSON。场景是一个位于世界坐标原点附近的 Lego 物体。渲染器已经训练好，只需要你输出相机轨迹参数。必须只输出一个 JSON 对象，不要输出 Markdown，不要解释。

允许的 `trajectory_type` 包括 `orbit`、`dolly`、`pan`、`tilt`、`orbit_dolly` 和 `compound`。基础字段包括 `scene`、`trajectory_type`、`num_frames`、`radius_start`、`radius_end`、`elevation_start_deg`、`elevation_end_deg`、`azimuth_start_deg`、`azimuth_end_deg`、`look_at`、`fov_deg` 和 `motion_summary`。

如果用户描述包含“先……然后……最后……”“同时”“过渡到”等复合镜头语义，请优先使用 `trajectory_type="compound"`，并额外输出 `keyframes`。每个关键帧包含归一化时间 `t`、半径 `radius`、俯仰角 `elevation_deg`、方位角 `azimuth_deg` 和视场角 `fov_deg`。关键帧必须包含 `t=0.0` 和 `t=1.0`，且 `t` 单调递增。

通用约束：所有轨迹都必须看向 `look_at=[0.0,0.0,0.0]`；“旋转一圈”对应约 360 度方位角变化；“半圈”对应约 180 度方位角变化；“推进/特写”要求 `radius_end < radius_start`；“拉远”要求 `radius_end > radius_start`；相机半径不得小于 2.5，避免穿过物体。

例如，对于“从高处俯视揭示 Lego，然后下降到平视并绕到右前方”的输入，模型应输出 `compound` 类型，并用至少三个关键帧分别表示高处俯视、下降过渡和右前方结束视角。实验脚本随后对 JSON 进行解析、范围检查和 Nerfstudio camera path 转换。

参考文献

- [1] A. Tewari, O. Fried, J. Thies, V. Sitzmann, S. Lombardi, K. Sunkavalli, R. Martin-Brualla, T. Simon, J. Saragih, M. Nießner, et al. State of the Art on Neural Rendering. *Computer Graphics Forum*, 39(2):701–727, 2020.
- [2] B. Mildenhall, P. P. Srinivasan, M. Tancik, J. T. Barron, R. Ramamoorthi, and R. Ng. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis. In *Proceedings of the European Conference on Computer Vision*, pp. 405–421, 2020.
- [3] B. Kerbl, G. Kopanas, T. Leimkühler, and G. Drettakis. 3D Gaussian Splatting for Real-Time Radiance Field Rendering. *ACM Transactions on Graphics*, 42(4):139:1–139:14, 2023.
- [4] J. L. Schönberger and J.-M. Frahm. Structure-from-Motion Revisited. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 4104–4113, 2016.
- [5] J. L. Schönberger, E. Zheng, M. Pollefeys, and J.-M. Frahm. Pixelwise View Selection for Unstructured Multi-View Stereo. In *Proceedings of the European Conference on Computer Vision*, pp. 501–518, 2016.
- [6] Y. Xie, T. Takikawa, S. Saito, O. Litany, S. Yan, N. Khan, F. Tombari, J. Tompkin, V. Sitzmann, and S. Sridhar. Neural Fields in Visual Computing and Beyond. *Computer Graphics Forum*, 41(2):641–676, 2022.
- [7] T. Müller, A. Evans, C. Schied, and A. Keller. Instant Neural Graphics Primitives with a Multiresolution Hash Encoding. *ACM Transactions on Graphics*, 41(4):102:1–102:15, 2022.

- [8] A. Yu, S. Fridovich-Keil, M. Tancik, Q. Chen, B. Recht, and A. Kanazawa. Plenoxels: Radiance Fields without Neural Networks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 5501–5510, 2022.
- [9] A. Chen, Z. Xu, A. Geiger, J. Yu, and H. Su. TensorRF: Tensorial Radiance Fields. In *Proceedings of the European Conference on Computer Vision*, pp. 333–350, 2022.
- [10] J. T. Barron, B. Mildenhall, M. Tancik, P. Hedman, R. Martin-Brualla, and P. P. Srinivasan. Mip-NeRF: A Multiscale Representation for Anti-Aliasing Neural Radiance Fields. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 5855–5864, 2021.
- [11] J. T. Barron, B. Mildenhall, D. Verbin, P. P. Srinivasan, and P. Hedman. Mip-NeRF 360: Unbounded Anti-Aliased Neural Radiance Fields. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 5470–5479, 2022.
- [12] J. T. Barron, B. Mildenhall, D. Verbin, P. P. Srinivasan, and P. Hedman. Zip-NeRF: Anti-Aliased Grid-Based Neural Radiance Fields. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 19697–19705, 2023.
- [13] A. Guédon and V. Lepetit. SuGaR: Surface-Aligned Gaussian Splatting for Efficient 3D Mesh Reconstruction and High-Quality Mesh Rendering. *arXiv preprint arXiv:2311.12775*, 2023.
- [14] Y. Jiang, J. Tu, Y. Liu, X. Gao, X. Long, W. Wang, and Y. Ma. GaussianShader: 3D Gaussian Splatting with Shading Functions for Reflective Surfaces. *arXiv preprint arXiv:2311.17977*, 2023.
- [15] J. Wang, J. Fang, X. Zhang, L. Xie, and Q. Tian. GaussianEditor: Editing 3D Gaussians Delicately with Text Instructions. *arXiv preprint arXiv:2311.16037*, 2023.
- [16] B. Huang, Z. Yu, A. Chen, A. Geiger, and S. Gao. 2D Gaussian Splatting for Geometrically Accurate Radiance Fields. *arXiv preprint arXiv:2403.17888*, 2024.
- [17] A. P. S, A. Melnik, and G. C. Nandi. Cognitive Planning for Object Goal Navigation using Generative AI Models. *arXiv preprint arXiv:2404.00318*, 2024.
- [18] X. Liu, Y.-W. Tai, and C.-K. Tang. ChatCam: Empowering Camera Control through Conversational AI. *arXiv preprint arXiv:2409.17331*, 2024.